

Ürün Reçetesi ve Talep Tahminlemesi ile Stok Yönetimi Optimizasyonu

Inventory Management Optimization Using Bill of Materials and Demand Forecasting

Efe Emir YÜCE

Muğla Sıtkı Koçman Üniversitesi, Bilgisayar Mühendisliği, efeemiryuce@gmail.com

ÖZET

Bu çalışmada, giyim sektöründe stok yönetimini optimize etmek amacıyla talep tahminlemesi ve ürün reçetesi (bill of materials-bom) yönetimi konularına odaklanılmıştır. Sentetik olarak üretilen bir koşu ayakkabısı satış verileri üzerinde SARIMA (Seasonal Autoregressive Integrated Moving Average) modeli kullanılarak geleceğe yönelik talep tahmini yapılmıştır. Ayrıca Django tabanlı bir ürün reçetesi yönetim sistemi geliştirilerek, çok katmanlı ürün reçetelerinin yönetilmesi sağlanmıştır. Bu bağlamda, gelecek talep tahmini yapılan ürünün, ürün reçetesi yönetim sistemi ile kullanılması sağlanmış ve hammadde ihtiyaç listesi çıkarılarak stok seviyelerinin yönetimi kolaylaştırılmıştır. Elde edilen sonuçlar, doğru bir talep tahmini ve ürün reçetesinin birlikte kullanımının, stok yönetiminin verimliliğinin artırabileceğini ve işletmelerin rekabet gücünü yükseltebileceğini göstermektedir.

Anahtar Kavramlar: Talep Tahmini, Ürün Reçetesi, Stok Yönetimi, Makine Öğrenmesi, Django, SARIMA

ABSTRACT

In this study, the focus is on demand forecasting and Bill of Materials (BOM) management to optimize inventory management in the clothing sector. Using sales data of a synthetically produced running shoe, future demand was forecasted with the SARIMA (Seasonal Autoregressive Integrated Moving Average) model. Additionally, a Django-based Bill of Materials management system was developed to manage multi-level product recipes. In this context, the product with a forecasted future demand was integrated into the BOM management system, and a raw material requirements list was generated, facilitating inventory level management. The results show that the combined use of accurate demand forecasting and BOM management can improve inventory management efficiency and enhance a company's competitive edge.

Keywords: Demand Forecasting, Bill of Materials, Inventory Management, Machine Learning, Django, SARIMA

1 GİRİŞ

Gelişen dünyada tedarik zincirleri giderek önem kazanıyor. Doğru yürütülen bir tedarik zinciri, hem minimum gecikmeyle müşterileri memnun eder hem de maliyeti kontrol altında tutarak işletmeler için fayda sağlar. Tedarik zincirini geliştirmenin önemli bir basamağı ise stok yönetimidir [1]. Stok yönetimi, gelecek talepler göz önüne alınarak stok miktarını mümkün olduğunca ekonomik ve optimum düzeyde tutmayı amaçlar.[2] İşletmeler için yüksek stok seviyesi tercihi, işletmenin stoğa bağlı maliyetini artırırken şirketin stok yönetimindeki esnekliğinin azalmasına ve israfa yol açar. Bu israf hem işletmeler için para kaybına hem de çevre için kötü sonuçlara yol açabilir. Diğer yandan işletmelerin düşük stok seviyesi tercihi talep sıklığına bağlı olarak işletmenin sipariş verme/hazırlık sürecinde yükünün artmasına, talebin veya tedarik/üretim süresinin belirsiz olduğu durumlarda taleplerin karşılanamamasına ve müşteri kaybına sebep olur [3]. Doğru bir stok yönetimi, işletmelerin nakit akışlarını kontrol altında tutmalarını ve ticari alanda aktif kalmalarını sağlar [4]. Büyüyen veriyi ve gelişen teknolojiyi kullanarak isabetli bir talep tahminlemesi yapmak stok yönetiminin verimini artırır [5].

Ürün reçetesi (bill of materials-bom) ürünlerin hammadde bileşenlere, bileşenlerden son ürüne kadar hiyerarşisini listeler. Ürün reçetesi satın alma, üretme, hazırlama gibi unsurlar için kritiktir [6]. Ürün reçetesi, stok fazlalığı veya eksikliği sebebiyle meydana gelebilecek sorunların önlenmesi için tahmin yöntemleriyle beraber kullanılır [7].

Talep, bir ürün veya hizmetin belirli bir fiyat düzeyindeyken tüketici tarafından alınmaya hazır olduğu tutardır [8]. Talep tahmini ise işletmelerin üretimi güvenli bir düzeyde sürdürmesine yarayan ve stratejik avantaj sağlayan önemli bir unsurdur. [9].

İsabetli bir talep tahmini, doğru bir tedarik zinciri yönetimini ve uygun stok yönetimi sayesinde müşteri memnuniyetini sağlar [10]. Ürün reçetesini de kullanarak talep tahminlemesi, stok yönetiminde büyük avantajlar sağlama potansiyeline sahiptir. Bu sayede işletmenin gelecek dönemde hangi ürüne ne kadar talep olacağını tahmin edebilir ve gerekli hammadde ve yarı bitmiş ürünleri temin etme imkânı olur.

İşletmelerin gelişen teknolojinin yarattığı rekabet ortamında tutunabilmeleri için talep tahminlemesi yapması ve stok yönetimini iyileştirmeleri elzemdir. Bu çalışma makine öğrenmesi yöntemlerini kullanarak isabetli bir talep tahminlemesi yapmak ve işletmelerin stok yönetimlerini iyileştirmeyi hedeflemektedir. Ürün reçetesinin de yardımıyla bu talep tahminlemesi doğrultusunda hammadde ve yarı bitmiş ürün ihtiyaçları da hesaplanarak tam bir ihtiyaç listesi oluşturularak stok yönetimini optimize etmek amaçlanmaktadır.

2 LİTERATÜR TARAMASI

Talep tahminlemesi işletmeler için stok yönetimi optimizasyonunda kritik rol oynayan bir stratejidir. Literatürde talep tahminlemesi üzerine enerji, tekstil, turizm, gıda gibi daha birçok sektörde çalışmalar bulunmaktadır. Gelişen teknolojiyle beraber talep tahminleme yöntemleri de çeşitlenmiştir. Literatürde geleneksel yöntemlerin ve makine öğrenmesi yaklaşımlarının karşılaştırıldığı birçok çalışma da mevcuttur.

Örneğin Alon ve ekibi, çalışmalarında toplam perakende satışlarının tahmin edilmesi üzerinde yapay sinir ağları ve Winters üstel düzeltme, Box-Jenkins ARIMA, çok değişkenli regresyon gibi geleneksel yöntemleri karşılaştırmışlar ve yapay sinir ağlarının daha iyi bir performans gösterdiğini gözlemlemişlerdir [11].

Veiga ve çalışma arkadaşları, yapmış oldukları çalışmada, gıda perakende sektöründe üç farklı bozulabilir gıda ürün grubunun satışlarını analiz ederek, ARIMA, Holt-Winter, Dalgacık Sinir Ağları (WNN) ve Takagi modellerini karşılaştırmışlardır. Çalışmanın sonucunda, tüm gruplarda en iyi performans gösteren modelin WNN olduğunu gözlemlemişlerdir [12].

Es ve ekip arkadaşları, Türkiye net enerji talebi tahmini üzerine yaptıkları çalışmada yapay sinir ağları modeli ve çoklu doğrusal regresyon metodunu karşılaştırmışlardır. Çalışmalarının sonucunda yapay sinir ağlarının daha iyi sonuçlar verdiğini gözlemlemişlerdir [13].

Loureiro ve ekibi, moda perakendesinde satış tahmini üzerine yaptıkları çalışmada derin öğrenme yaklaşımı ile karar ağaçları, rassal orman, destek vektör regresyonu, yapay sinir ağları ve doğrusal regresyon gibi teknikleri karşılaştırmıştır. Sonuç olarak ise kullandıkları model tekstil alanında satış tahmin etme konusunda iyi bir performansa sahip olduğu gözlemlenmiştir. Diğer yandan bir takım değerlendirme metriklerine göre rassal orman algoritmasının daha iyi sonuçlar verebileceği gözlemlenmiştir [14].

Falatouri ve ekibinin tedarik zinciri yönetimi üzerine yaptıkları çalışmada, SARIMA ve LSTM modellerini karşılaştırmayı amaçlamışlardır. Çalışmalarının sonucunda her iki modelin de yeterli sonuçlar vermiştir. Ancak LSTM modelinin istikrarlı talebe sahip ürünlerde daha iyi performans gösterdiğini, SARIMA modelinin ise mevsimsel davranışlara sahip ürünlerde daha iyi performans gösterdiğini gözlemlemişlerdir [15].

Law ve ekip arkadaşları, turizm talep tahmini üzerine bir çalışma yürütmüşlerdir. Çalışmalarında turist varış hacimlerini tahmin etmek için derin öğrenme yaklaşımını kullanmış olup destek vektör regresyonu ve yapay sinir ağı modelleriyle karşılaştırmışlardır. Sonuç olarak derin öğrenme yaklaşımının daha iyi bir performans gösterdiğini gözlemlemişlerdir [16].

Aydın ve Yazıcıoğlu ise perakende sektöründe bir süpermarketin kasap reyonunun müşteri talep tahmini üzerine çalışmışlardır. Çalışmalarında bir zaman serisi yöntemi olan ARIMA ile yapay sinir ağı modellerini karşılaştırmışlardır. Çalışmalarının sonucunda yapay sinir ağları modelinin daha iyi bir sonuç verdiği sonucuna ulaşmışlardır [17].

Kang ve ekibi, bisiklet kiralama sayısının tahmini üzerine yaptıkları çalışmada çoklu doğrusal regresyon, karar ağaçları ve rassal orman algoritmalarının performanslarını karşılaştırmışlardır. Bu çalışma sonucunda en iyi performansı rassal orman algoritmasının verdiğini gözlemlemişlerdir [18].

Büşra Yüksel, depo planlaması için yaptığı talep tahminlemesi çalışmasında bir perakende şirketinin satış verilerini kullanarak ARIMA, SARIMA, SARIMAX, LSTM, LightGBM, CatBoost, XGBoost ve multiple linear regression modellerini karşılaştırmıştır. En iyi performansı Catboost modelinin verdiğini saptamıştır [19].

3 VERİ

Bu çalışmada kullanılmak üzere ürün reçetesi örneği ve geçmiş satış miktarları olarak iki farklı veri setine ihtiyaç vardır. Bu veriler, çalışmanın yapısı gereği gerçekçi bir şekilde sentetik olarak üretilirse gerçekçi sonuçlar verecektir. Bu konudaki verinin yetersizliği sebebiyle sentetik veri yöntemine başvurulmuştur. Sentetik veri üretiminde OpenAI tarafından geliştirilen ChatGPT-4o yapay zeka modelinden yardım alınmıştır [20].

Ayrıca ürün reçetesi örneği ve geçmiş satış miktarları veri setleri birbirini desteklemelidir. Geçmiş satış miktarı verilen ürünün, ürün reçetesi örneğindeki son ürün olması lazımdır. Çünkü çalışmanın hedefi bir ürünün satış tahminini sağlayıp aynı ürünün hammadde ihtiyaç listesini çıkarmaktır. Bunun için örnek olarak giyim sektöründe bir koşu ayakkabısı tercih edilmiştir.

3.1 Ürün Reçetesi İçin Veri Üretimi

Bir ürün reçetesi; bir ürünün kendisini, yarı bitmiş ürünlerini ve miktarlarını, hammaddelerini ve miktarını, yarı bitmiş ürünlerin de hammadde ve miktarlarını hiyerarşik olarak listelemelidir. Çalışmada kullanılmak üzere örnek olarak seçilen koşu ayakkabısı için ChatGPT-4o yapay zeka modeli kullanılarak bir ürün reçetesi örneği, sentetik olarak üretilmiştir [20]. Bu veri, daha sonra ürün reçetesi yönetim sisteminde kullanılmak üzere JSON formatına dönüştürülmüştür. Verinin tablolatırılmış hali şu şekildedir:

Tablo 1: ChatGPT’den elde edilen sentetik koşu ayakkabısı verisi

Bileşen İsmi	Tür	Miktar	Birim	Üst Ürün	Stok Kodu
Koşu Ayakkabısı (Çift)	Son Ürün	1	Çift		RS001
Koşu ayakkabısı üst kısmı (Çift)	Yarı-Bitmiş Ürün	1	Çift	Koşu Ayakkabısı	UA001
File kumaş	Hammadde	0.6		Metrekare	Koşu ayakkabısı üst kısmı (Çift)
Sentetik deri	Hammadde	0.3		Metrekare	Koşu ayakkabısı üst kısmı (Çift)
Bağcık sistemi	Hammadde	1	Çift	Koşu ayakkabısı üst kısmı (Çift)	
Koşu ayakkabısı tabanı (Çift)	Yarı-Bitmiş Ürün	1	Çift	Koşu Ayakkabısı	SA001
Kauçuk dış taban	Hammadde	35	Metrekare	Koşu ayakkabısı tabanı (Çift)	
EVA Köpük	Hammadde	300	Gram	Koşu ayakkabısı tabanı (Çift)	
Astar	Hammadde	1	Çift	Koşu Ayakkabısı	
Topuk dolgusu	Hammadde	1	Çift	Koşu Ayakkabısı	
Burun koruması	Hammadde	1	Çift	Koşu Ayakkabısı	
Tutkal	Hammadde	50	Mililitre	Koşu Ayakkabısı	


3.2 Tahmin Algoritması İçin Veri Üretimi

Çalışmanın talep tahminlemesi amacına ulaşabilmesi için ihtiyaç duyduğu bir diğer veri olan geçmiş satış verileri de ChatGPT-4o yapay zeka modelinden yardım alınarak oluşturulmuştur [20]. Bir giyim firmasına ait olabilecek gerçekçi bir koşu ayakkabısı satış verisi, toplamda 10 yıllık olmak üzere her ay için satış miktarını içerecek şekilde üretilmiştir. Tarih, kategori ve satış kolonlarına sahip olan satış verisi 2014-2024 yılları arasında koşu ayakkabısı satışlarını temsilen 120 veri noktası içermektedir. Her bir satırda ay bazında satış miktarı içeren veri, daha sonra işlenmek üzere csv formatında üretilmiştir.

3.2.1 Tahmin Algoritması İçin Oluşturulan Verinin Analizi

Sentetik üretilen verinin sistemde kullanılmadan önce analizi yapılması önemlidir. Analizi yapılan verinin hem gerçekçiliği doğrulanır hem de verinin ne çeşit bir yönelime sahip olduğu anlaşılır ki bu sayede doğru talep tahmin metodu uygulanabilir.


Veri seti herhangi bir eksik veya hatalı veri içermemekte ve doğrudan satış tahmini için uygun hale getirilmiştir. Aylık satışların zaman serisi grafiği Figür 1’deki gibi gözükmemektedir. Grafikten anlaşılabileceği üzere veride mevsimsel bir dalgalanma mevcuttur. Bunun anlamı, satılan ürüne sene içinde belirli aylarda talep artışı olurken diğer aylarda bu talep düşmektedir.



Figür 1: Koşu ayakkabısı 10 yıllık satış verileri


Verinin mevsimsellik ve trend analizi yapıldığında, satışların yaz aylarında arttığı ve kış aylarında düştüğü gözlemlenmiştir. Bunun yanı sıra, yıllar içinde satışların genel olarak artma eğiliminde olduğu ve bunun sonucunda koşu ayakkabılarına olan talebin zaman içerisinde arttığı tespit edilmiştir. Mevsimsellik ve trend grafiği Figür 2’deki gibi incelenebilir. Trend grafiğinde satışların

zamanla artma eğiliminde olduğu, mevsimsellik grafiğinde ise mevsimsel bileşenin senenin belirli aylarında düzenli olarak değiştiği gözlemine dayanarak satışların senenin belirli zamanlarında düştüğü ve yükseldiği gözlemlenebilir.



Figür 2: Satış verilerinin mevsimsellik ve trend analizi

Veriye otokorelasyon analizi uygulandığında, Figür 3'te de görülebileceği üzere her 12 ayda bir tekrarlayan güçlü bir korelasyon olduğu saptanmıştır. Grafikte de incelenebileceği üzere, otokorelasyon katsayısı belirli bir patern izlemektedir. Bu durum, koşu ayakkabısı satışlarının yıllık bir mevsimsel döngü içerisinde olduğunu ve satışların mevsimsel bir yol izlediğini doğrulamaktadır.




Figür 3: Satış verilerinin otokorelasyon analiz grafiği

4 ÜRÜN REÇETESİ YÖNETİM SİSTEMİ

Bu çalışmada ürün reçetesi yönetimini gerçekçi yapmak, kolaylaştırmak ve optimize etmek amacıyla Django tabanlı basit bir web uygulaması geliştirilmiştir. Bu uygulama sayesinde ürün reçetesi kolayca sisteme entegre edilir ve işlenebilir. Django'nun sağladığı modüler yapı ve veri tabanı yönetimi, bu tür bir sistemin etkili ve esnek bir şekilde geliştirilmesine olanak tanımıştır.

4.1 Django Tabanlı Ürün Reçetesi Yönetim Sistemi

Ürün reçetesi yönetimini kolaylaştırmayı amaçlayan bu web uygulamasında anasayfa, ürünler, hammaddeler ve ürün reçeteleri olmak üzere 4 ana sekme vardır. Figür 4'te görüldüğü üzere navigasyon barından sisteme kayıtlı tüm ürünlere, hammaddelere ve ürün reçetelerine ulaşmak mümkündür.



Figür 4: Ürün reçetesi anasayfası ve navigasyon barı

Örneğin, Figür 5'te de görülebileceği üzere ürünler sekmesinde sisteme kayıtlı tüm bitmiş ve yarı bitmiş ürünler incelenebilirken listelenen her ürünün altında bulunan “Gelecek ay için hammadde ihtiyaç tahmini” butonu kullanılarak, bu çalışmanın amacı olan talep tahmini doğrultusunda hammadde ihtiyacı tespiti yapılabilmektedir.



Figür 5: Ürün reçetesi yönetim sisteminin ürünler sekmesi

Ayrıca tüm sekmelerde listelenen objeler tıklanılabilir olup tıklanılan objenin detaylar sayfasına yönlendirme yapmaktadır. Figür 6'da görülebileceği üzere, bu sayede ister ürün ister hammadde ister ürün reçetesi olsun her objenin açıklama, stok kodu, birim, alt ürünler gibi detaylarını incelemek mümkündür.

Hammadde detayları: File kumaş

Hammadde birimi: metrekare

Hammadde açıklaması: Nefes alabilen file kumaş

[Güncelle](#)

Figür 6: Ürün reçetesi yönetim sisteminde file kumaş hammadde detayları

4.2 Ürün Reçetesi Verilerini Modelleme

Sistemin en kritik yeri modellemedir. Sistemin amacı olan ürün reçetelerini yönetmenin nasıl yapılacağına, verilerin nasıl işleneceğine burada karar verilir. Bir ürün reçetesi son ürün, yarı bitmiş ürünler ve hammaddelerden oluşur. Modelleme kısmında bu 3 objeyi de iyi işlemek sistemin verimliliği ve doğruluğu açısından kritiktir.

Ürün modellemesinde, ürüne ait isim, açıklama ve stok kodu özellikleri bulunmaktadır. Stok kodu ürünü diğer ürünlerden ayıran özelliği olduğundan kritiktir.

Hammadde modellemesinde ise, hammaddenin isim, açıklama, birim özellikleri vardır. Hammaddenin birim özelliği ürün reçetesi oluştururken elzemdir. Sonuçta elde edilecek sayının hangi birim olduğu bilinmezse sistemin doğruluğu ciddi anlamda zedelenir.

Son olarak ürün reçetesi modellemesinde, son ürün, hammadde, yarı bitmiş ürün ve miktar özellikleri vardır. Son ürün, ürün reçetesi hiyerarşisinde en tepedeki bitmiş ürünü temsil eder. Hammadde ve yarı bitmiş ürün ise son ürünün bileşenlerini temsil eder. Son ürün ve yarı bitmiş ürün özellikleri Django'nun one-to-one özelliği kullanılarak ürün modeline bağlanmıştır. Hammadde özelliği ise aynı şekilde one-to-one kullanılarak hammadde modeline bağlanmıştır. Miktar özelliği ise son ürünün bileşeni olan yarı bitmiş ürünün veya hammaddenin miktarını nitelendirmeyi amaçlamaktadır.

Bu sistemde ürün reçetesi modelinin çok katmanlı(multi-level) olması amaçlanmıştır. Bunun anlamı, bir ürün reçetesinde son ürün sadece hammaddelerden değil hem yarı bitmiş ürünlerden hem de hammaddelerden oluşmaktadır. Bu sebeple ürün reçetesi modelinde hem hammadde hem de yarı bitmiş ürün özelliği vardır. Sisteme bir ürün reçetesi verisi yüklenirken, sistem tüm bileşenleri ürün reçetesi modelini kullanarak tek tek son ürüne bağlayıp birbirinden ayrı objeler şeklinde oluşturmaktadır. Bu birbirinden ayrı objelerde son ürüne ya hammadde ya da yarı bitmiş ürün özelliği bağlanır. Bu şekilde miktar özelliği doğru özelliğe bağlanarak verimli bir sonuç çıkarır. Bu modelleme kodları pseudo code olarak şu şekilde incelenebilir:

Class Product:

Attributes:

- name (unique string, max length 100)
- description (optional text field)
- sku (unique string, max length 50)

Class RawMaterial:

Attributes:

- name (unique string, max length 100)
- description (optional text field)
- unit (string, max length 20)

Class BillOfMaterials:

- final_product (references Product, required)
- raw_material (references RawMaterial, optional)
- semi_finished_product (references Product, optional)
- quantity (float)

Modellemenin basitleştirilmiş ve pseudo code haline getirilmiş versiyonundan da anlaşılacağı üzere, ürün modelinin isim (name), açıklama (description) ve stok kodu (sku) olarak 3 özelliği; hammadde modelinin isim (name), açıklama (description) ve birim (unit) olarak 3 özelliği; ürün reçetesi modelinin ise son ürün (final product), hammadde (raw material), yarı bitmiş ürün (semi finished product) ve miktar (quantity) olarak 4 özelliği bulunmaktadır. Ürün reçetesi modelinden bir obje oluşturulacağı zaman, hammadde veya yarı bitmiş ürün özelliklerinden biri alınıp miktar değeri ona bağlanır. Son ürünü aynı olan ürün reçetesi objeleri sistem tarafından sonrasında birleştirilir ve hiyerarşiyi kurar.

4.3 Ürün Reçetesi Verilerinin Yönetim Sisteminde Görünümü

Oluşturulan ürün reçetesi modeli sayesinde, daha önce sentetik şekilde üretilen koşu ayakkabısı verisi sisteme kolayca aktarılabilir ve yönetilebilir. JSON formatında oluşturulan veriyi sisteme tanıttuktan sonra veride bulunan son ürün ve yarı bitmiş ürünler, sistemin navigasyon barındaki ürünler sekmesinden; hammadde bileşenleri, hammaddeler sekmesinden ve ürün reçetesinin tamamı, ürün reçeteleri sekmesinden incelenebilir. Ayrıca Figür 7’de incelenebileceği üzere, ürün reçeteleri sekmesinde, detayları incelenmek istenen bir ürün reçetesine tıklanabilir, detayları ve alt bileşenleri gözlemlenebilir. Ürün reçetesindeki yarı bitmiş ürünler de sistem tarafından ayrı bir ürün reçetesi olarak kabul edildiğinden, ürün reçeteleri sekmesinden aynı şekilde gözlemlenebilir.

Ürün detayları: Koşu Ayakkabısı (Çift)

Ürün açıklaması: Yüksek kalite koşu ayakkabısı (Çift)

Koşu Ayakkabısı (Çift) Ürün reçetesi

- Koşu ayakkabısı üst kısmı (Çift) 1.0 adet
- Koşu ayakkabısı tabanı (Çift) 1.0 adet
- Astar 1.0 çift
- Topuk dolgusu 1.0 çift
- Burun koruması 1.0 çift
- Tutkal 50.0 mililitre

[Güncelle](#)

Figür 7: Ürün reçetesi yönetim sisteminde seçilen ürün reçetesinin özellikleri

4.4 Ürün Reçetesi Yönetim Sistemine Kullanıcının Girdi Yapması

JSON tipinde üretilen veriler, sisteme kod yoluyla doğrudan entegre edilmiştir. Ancak kullanıcıların girdi yapabilmesi için bir arayüze ihtiyaç vardır. Ürünler, Hammaddeler ve Ürün Reçeteleri sekmelerinde bulunan “Yeni ekle” butonu kullanılarak kullanıcı kendisi veri girdisi yapabilmektedir. Modellemelerle paralel çalışması gereken sistemde kullanıcı ürünlere yeni veri eklemek istediğinde isim, açıklama ve sku bilgileri istenirken hammaddelere yenisi eklenmek istendiğinde isim, açıklama ve birim bilgileri istenir.

Kullanıcı yeni bir ürün reçetesi oluşturmak istediğinde ise Figür 8’de de görülebileceği üzere son ürün, hammadde, yarı bitmiş ürün ve miktar değerleri kullanıcıdan istenmektedir. Sistemin optimal çalışabilmesi için kullanıcının tüm ürün reçetesi elementlerini tek tek ve ayrı ayrı kaydetmesi gerekmektedir. Son ürüne, yarı bitmiş ürünleri bağlayabilmek için önce yarı bitmiş ürünlerin ürün reçetesi, tüm hammaddeler ayrı ayrı kaydedilerek oluşturulmalı ve finalde son ürüne yarı bitmiş ürün kaydedilmeli. Ayrıca her ayrı ayrı oluşturulan ürün reçetesi verisinin ya yarı bitmiş üründen ya da hammaddeden oluşması gerekir. Son ürüne aynı anda hem yarı bitmiş ürün hem de hammadde verisi girilmeye çalışılırsa, miktar değeri doğru özelliğe bağlanmayabilir.

Bunlar dikkate alınarak kullanıcı tarafından sisteme ürün ve hammadde bilgisi girilebilir ve sıfırdan bir ürün reçetesi verisi oluşturulabilir.

BOM

Anasayfa

Ürünler

Hammaddeler

Ürün reçeteleri

Yeni Ürün Reçetesi Oluştur

Final product: -----

Raw material: -----

Semi finished product: -----

Quantity:

Kaydet

Figür 8: Ürün reçetesi yönetim sistemi, ürün reçetesi ekleme sayfası

4.5 Ürün Reçetesi Yönetim Sisteminde Verilerin Güncelleştirilmesi

Son olarak ürün detayları, hammadde detayları ve ürün reçetesi detayları sekmelerindeki “Güncelle” butonu kullanılarak verilerde kullanıcı tarafından değişiklik yapılabilir. Hangi ürünün veya hammaddenin detay sayfasındaki “Güncelle” butonu kullanılırsa o ürün veya hammaddenin üzerinde değişiklik gerçekleştirilebilen bir sayfa gelir. Figür 9’da örnek verilen ürün güncelleme sayfasında da görülebileceği üzere güncelleme sayfası aynı yeni ekle sayfası gibi modellemeyle paralel bilgiler istemektedir. Ancak bu bilgiler incelenen verinin bilgileri ile hali hazırda dolu gelmektedir. Kullanıcı istediği bilgileri değiştirebilmektedir.

BOMAnasayfaÜrünlerHammaddelerÜrün reçeteleri

Koşu Ayakkabısı (Çift) Ürünü Güncelle

Name: Koşu Ayakkabısı (Çift)

Yüksek kalite koşu ayakkabısı (Çift)

Description:

Sku: RS001

Kaydet

Figür 9: Ürün reçetesi yönetim sistemi, ürün güncelleme sayfası


5 TALEP TAHMINİ MODELİ

Koşu ayakkabısı satış verilerinin analizine göre, satışların mevsimsel bir kalıp içerdiği gözlemlenmiştir. Bu doğrultuda talep tahmini için SARIMA (Seasonal AutoRegressive Integrated Moving Average) modeli uygun bulunmuştur.

SARIMA zaman serisi analizleri için sıkça kullanılan bir model olmakla birlikte klasik ARIMA modelinin genişletilmiş bir versiyonudur. Özellikle mevsimler yapıdaki verilerde etkili sonuçlar vermektedir. Giyim sektöründe mevsimsel dalgalanmalar sıkça görüldüğünden bu sektörde bir talep tahmininde SARIMA modelini kullanmak uygundur.

5.1 SARIMA Modelinin Uygulanması

Eldeki satış değerleri verisi SARIMA modelini eğitmek amaçlı, son 24 değer test, kalan değerler eğitim olarak bölünmüştür. Bu değerlerle eğitilen SARIMA modelinden test amaçlı olan son 24 değer tahmini istendiğinde isabetli bir sonuç çıkardığı gözlemlenmiştir. Figür 10'da SARIMA modelinin verdiği sonuçların ve güven aralığının grafiği incelenebilir.



Figür 10: SARIMA modeli tahmin ve güven aralığı grafiği

Oluşturulan SARIMA modelinin, bu çalışmada kullanılan verilerle güvenilir sonuçlar çıkardığı gözlemlenmiştir. Ancak çalışmanın asıl hedefi, eldeki verilerle eğitilen SARIMA modelinden gelecek ay için bir talep tahmini elde etmektir. Bu doğrultuda verinin tamamı SARIMA modelini eğitmekte kullanıldıktan sonra, modele gelecek ay için talep tahmini yaptırılmıştır. Modelin verdiği tahmini değer 444.08585 olarak gözlemlenmiştir.

5.2 Tahmin Modelinin Ürün Reçetesi Yönetim Sistemiyle Birlikte Kullanılması

Oluşturulan SARIMA modeli Django tabanlı ürün reçetesi yönetim sistemine entegre edilmiştir. Aynı şekilde sentetik üretilen koşu ayakkabısı satış verileri de sisteme yüklenmiştir. Sistem, SARIMA modelinden elde ettiği gelecek ayın talep tahminini ürün reçetesini de kullanarak, istenen ürünün gelecek ayda hangi hammaddeden yaklaşık olarak hangi miktarda ihtiyaç olacağını tahmin etmektedir. Web uygulamasında, ürünler sekmesinden istenen ürünün altındaki “Gelecek ay için hammadde ihtiyaç tahmini” butonuna tıklanarak bu sonuçlar gözlemlenebilir hale getirilmiştir. Koşu ayakkabısı için sistemin verdiği hammadde ihtiyaç tahmin sonuçlarının tablolaştırılmış hali aşağıdaki gibidir:

Tablo 2: Gelecek ay için hammadde ihtiyaç tahmini verileri

Hammadde	Gerekli Miktar	Birim
File Kumaş	266.45151	Metrekare
Sentetik deri	133.225755	Metrekare
Bağcık sistemi	444.08585	Çift
Kauçuk dış taban	155.4300475	Metrekare
EVA Köpük	133225.755	Gram
Astar	444.08585	Çift
Topuk dolgusu	444.08585	Çift
Burun koruması	444.08585	Çift
Tutkal	22204.2925	Mililitre

6 SONUÇ

Bu çalışmada, giyim sektöründe bir firmanın stok yönetimini optimize etmek amacıyla ürün reçetesi yönetimi ve talep tahminleme konularına odaklanılmıştır. Örnek olarak bir koşu ayakkabısı satış verileri üzerinden SARIMA modeli kullanılarak talep tahmini yapılmıştır. Talep tahmini yapılırken verinin mevsimsel etkileri göz önünde bulundurulmuş ve güvenilir sonuçlar elde edilmiştir. Geliştirilen Django tabanlı ürün reçetesi yönetim sistemi, ürün reçetesi yönetimini kolaylaştırmış ve hammadde, yarı bitmiş ürünler, son ürün hiyerarşisini çok katmanlı bir şekilde yönetilmesine olanak sağlamıştır. Yapılan talep tahmini doğrultusunda firmanın gelecek dönem hammadde ihtiyacı tahmin edilip stok yönetimi optimize edilmiştir.

Bu çalışma ile elde edilen sonuçlar, stok yönetimi ve talep tahminlemesi alanında işletmelere veri odaklı kararlar almaları konusunda katkı sağlamıştır. Doğru yapılan talep tahmini stok seviyelerini optimize etmeye yardımcı olur ve bu doğrultuda müşteri memnuniyetini artırırken maliyetleri düşürmeye yardımcı olur. Talep tahminlemesi, doğru bir ürün reçetesi yönetimiyle birleştirilirse hammadde ihtiyaçları daha net bir şekilde görülebilir ve stok yönetimini kolaylaştırır.

Çalışmada kullanılan tahmin modeli, daha büyük veri setleri kullanılarak doğruluğu artırılabilir. Aynı şekilde bu tahmin modeli, farklı makine öğrenmesi yöntemleri kullanılarak geliştirilebilir ve çok daha geniş bir sektör yelpazesine hitap edebilir. Tedarik zinciri yönetimine de entegre edilerek işletmelerin rekabet gücünü ciddi anlamda artırılabilir.

Bunların yanı sıra çalışmada gerçekleştirilen Django tabanlı ürün reçetesi yönetim sistemi, özellikle kullanıcı deneyimi açısından çok daha geliştirebilir olup gerçek hayata entegre edilme potansiyeli çok daha güçlendirilebilir.

7 REFERANSLAR

- [1] Hector D.Perez, Christian D.Hubbs, Can Li and Ignacio E. Grossmann. 2021. Algorithmic Approaches to Inventory Management Optimization. <https://doi.org/10.3390/pr9010102>.
- [2] Vehbi Yüksel, Ahmet Duman. 2017. ECZANELERDE STOK YÖNETİMİ. <https://dergipark.org.tr/en/pub/lectiosc/issue/37574/434344>.
- [3] Elif Bilgin Yusuf Ulusoy. 2021. TALEP TAHMİNİ VE STOK YÖNETİMİ ÜZERİNE BİR UYGULAMA. https://www.researchgate.net/publication/354854243_Talep_Tahmini_ve_Stok_Yonetimi_Uzerine_Bir_Uygulama.
- [4] Emine Genç İbrahim Tunali. 2021. STOK YÖNETİMİ VE ERP: ENERJİ SEKTÖRÜNDE BİR UYGULAMA. 10.26449/sss.3684.
- [5] Fatima Zohra Benhamida, Ouahiba Kaddouri, Tahar Ouhrouche, Mohammed Benaichouche, Diego Casado-Mansilla, Diego Lopez-de-Ipi ´ na. 2021. Demand Forecasting Tool For Inventory Control Smart Systems. <https://doi.org/10.24138/jcomss-2021-0068>.
- [6] Hailin Zhang. 2018. Development of cost management and aided decision system for casting enterprises basedon ERP. <https://doi.org/10.1051/itmconf/20181703010>.
- [7] M. A. Kamal, F. D. Effendi, M. R. Utomo, S. Sucipto, I. Santoso and U. Effendi. Bill of material analysis framework of food menu to increase raw material inventory efficiency halal food inspection of culinary business. <https://doi.org/10.1088/1755-1315/733/1/012043>.
- [8] Yücesoy, Mihriban. 2011. Temizlik Kağıtları Sektöründe Yapay Sinir Ağları İle Talep Tahmini. <https://polen.itu.edu.tr/items/de66e4b8-e788-47da-9ab6-b5f9480e9019>.
- [9] Ahmet Tezcan Tekin, Cem Sarı. 2022. Mağaza Tabanlı Talep Tahmini: Topluluk Öğrenmesi Yaklaşımları ile Zaman Serisi Yaklaşımı Karşılaştırılması. https://www.researchgate.net/publication/366228208_Magaza_Tabanli_Talep_Tahmini_Topluluk_Ogrenmesi_Yaklasimlari_ile_Zaman_Serisi_Yaklasimi_Karsilastirilmesi.
- [10] Ajay Kumar, Ravi Shankar, Naif Radi Aljohani. 2020. A big data driven framework for demand-driven forecasting with effects of marketing-mix variables. <https://doi.org/10.1016/j.indmarman.2019.05.003>.
- [11] Ilan Alon, Min Qi, Robert J. Sadowski. 2001. Forecasting aggregate retail sales: a comparison of artificial neural networks and traditional methods. [https://doi.org/10.1016/S0969-6989\(00\)00011-4](https://doi.org/10.1016/S0969-6989(00)00011-4).
- [12] Claudimar Pereira da Veiga, Cássia Rita Pereira da Veiga, Weslly Puchalski, Leandro dos Santos Coelho, Ubiratã Tortato. 2016. Demand forecasting based on natural computing approaches applied to the foodstuff retail segment. <https://doi.org/10.1016/j.jretconser.2016.03.008>.
- [13] Hüseyin Es, F. Yeşim Kalender, Coşkun Hamzaçebi. 2014. YAPAY SİNİR AĞLARI İLE TÜRKİYE NET ENERJİ TALEP TAHMİNİ. <https://dergipark.org.tr/en/pub/gazimmfd/issue/6708/89568>.
- [14] A.L.D. Loureiro, V.L. Miguéis, Lucas F.M. da Silva. 2018. Exploring the use of deep neural networks for sales forecasting in fashion retail. <https://doi.org/10.1016/j.dss.2018.08.010>.
- [15] Taha Falatouri, Farzaneh Darbanian, Patrick Brandtner, Chibuzor Udokwu. 2022. Predictive Analytics for Demand Forecasting – A Comparison of SARIMA and LSTM in Retail SCM. <https://doi.org/10.1016/j.procs.2022.01.298>.
- [16] Rob Law, Gang Li, Davis Ka Chio Fong, Xi Han. 2019. Tourism demand forecasting: A deep learning approach. <https://doi.org/10.1016/j.annals.2019.01.014>.
- [17] Muhammed Resul Aydın, Osman Yazıcıoğlu. 2019. YAPAY SİNİR AĞLARI İLE TALEP TAHMİNİ: PERAKENDE SEKTÖRÜNDE BİR UYGULAMA. <https://dergipark.org.tr/en/download/article-file/1195903>.
- [18] Zilu Kang, Yuting Zuo, Zhibin Huang, Feng Zhou, Penghui Chen. 2018. **Research on the Forecast of Shared Bicycle Rental Demand Based on Spark Machine Learning Framework. 10.1109/DCABES.2017.55.**
- [19] Büşra Yüksel. Zaman Serilerinde Talep Tahmini (Demand Prediction In Time Series). YBS Ansiklopedi Cilt 11, Sayı 2, Haziran 2023. <https://ybsansiklopedi.com/cilt-11-sayi-2-haziran-2023/>.
- [20] **OpenAI.** <https://openai.com/>.